# Ανάπτυξη Λογισμικού για Πληροφοριακά Συστήματα

Παναγιώτης Φωτόπουλος sdi1300195@di.uoa.gr

Μάνος Πιτσικάλης sdi1300143@di.uoa.gr

Χειμερινό εξάμηνο ακαδημαϊκού έτους 2016-2017

## 1 Εισαγωγή - Γενικά

## 2 Λεπτομέρειες υλοποίησης Part 1

### • Δομές αποθήκευσης

Για την αποθήκευση του γράφου χρησιμοποιούνται δύο ευρετήρια (index-buffer): ένα για τις εξερχόμενες ακμές και ένα για τις εισερχόμενες ακμές. Στις αναζητήσεις και γενικά όπου χρειάζονται λίστες, για την αποφυγή πολλών malloc χρησιμοποιούνται λίστες υλοποιημένες με πίνακα, οι οποίες και επαναχρησιμοποιούνται όταν χρειαστεί. Δηλάδη γινέται μια φορά malloc, αν χρειαστεί γίνεται realloc, και με την λήξη της εκτέλεσης γίνεται η αποδέσμευση της μνήμης. Επιπλέον, στις αναζητήσεις και όπου αλλού χρειάζεται δομή για να σημαδεύονται οι κόμβοι (π.χ.στην bidirectional-bfs η δομή visited) χρησιμοποιείται πίνακας A ίσος με τον αριθμό των στοιχείων με versioning, δηλαδή αν το στοιχείο x έχει επισκεφτεί οταν γίνεται αναζήτηση με version x τότε x τότε x αν κάποιο στοιχείο x δεν έχει επισκεφτεί τότε θα ισχύει x έτσι η αρχικοποιήση γίνεται μόνο μία φορά και ο έλεγχος γίνεται σε x x οι x εχει επισκεφτεί τότε θα ισχύει x ετσι η αρχικοποιήση γίνεται μόνο μία φορά και ο έλεγχος γίνεται σε x x εχει επισκεφτεί τότε θα ισχύει x ετσι η αρχικοποιήση γίνεται μόνο μία φορά και ο έλεγχος γίνεται σε x εχει επισκεφτεί τότε θα ισχύει x ετσι η αρχικοποιήση γίνεται μόνο μία φορά και ο έλεγχος γίνεται σε x εχει επισκεφτεί τότε θα ισχύει x ετσι η αρχικοποιήση γίνεται μόνο μία φορά και ο έλεγχος γίνεται σε x εχει επισκεφτεί τότε θα ισχύει x ετσι η αρχικοποιήση γίνεται μόνο μία φορά και ο έλεγχος γίνεται σε x εχει επισκεφτεί τότε θα ισχύει x ετσι η αρχικοποιήση γίνεται μόνο μία φορά και ο έλεγχος γίνεται σε x εχει επισκεφτεί τότε θα ισχύει x ετσι η αρχικοποιήση γίνεται μόνο μία φορά και ο έλεγχος γίνεται σε x εν επομέρες το εχει επισκεφτεί τότε θα ισχύει x ετσι η αρχικοποιήση γίνεται μόνο μία φορά και ο έλεγχος γίνεται σε x εχει επισκεφτεί το εχει επισκεφτεί το εχει επισκεφτεί εχει επισκεφτ

#### • Αναζήτηση

Για την αναζήτηση χρησιμοποιήθηκε η bidirectional Breadth-First Search, όπως περιγράφεται στην εκφώνηση, με τις εξής λεπτομέρειες/βελτιώσεις:

- Στην αρχή της κάθε επανάληψης, θα επιλεχθεί για επέκταση η BFS η οποία έχει την χαμηλότερη τιμή στην εξής ευρετική:
  - <αριθμός "παιδιών" προς επέκταση> + <αριθμός "εγγονιών" προς επέκταση (σε επόμενη επανάληψη)>
  - Με αυτόν τον τρόπο, αποφεύγεται η σπατάλη χρόνου σε καταστάσεις όπου από τη μία κατεύθυνση υπάρχουν πάρα πολλά πιθανά μονοπάτια, ενώ από την άλλη λίγα ή μόνο ένα.
- Η αναζήτηση γίνεται ανά "επίπεδα": Σε κάθε επανάληψη, η τρέχουσα BFS επισκέπτεται **όλα** τα παιδιά του τρέχοντος βάθους.

#### • Unit testing

Έχει υλοποιηθεί unit testing στις βασικές δομές με χρήση check. Για την σώστη λειτουργία του είναι απαραίτητο να υπάρχει εγκατεστημένο το <u>Check</u>.

### • Εισαγωγή ακμών

Κατά την εισαγωγή αχμών, ο έλεγχος ύπαρξης αχμής γίνεται στον χόμβο με τις λιγότερες αχμές

στην αντίστοιχη κατεύθυνση (εισερχόμενες-εξερχόμενες) για εξοικονόμηση χρόνου. Δοκιμάστηκε η χρήση hashtable για να γίνεται σε O(1) ο έλεγχος αυτός, αλλά αυτή η προσέγγιση αποδείχθηκε μη αποδοτική καθώς επηρέαζε σημαντικά τη χρήση μνήμης, καθώς και τον συνολικό χρόνο (ενημέρωση του hashtable). Σημείωση: υπάρχουν τα αρχεία για το hash table (hash.c, hash.h), αλλά δεν χρησιμοποιούνται στο τελικό πρόγραμμα.

## 3 Λεπτομέρειες υλοποίησης Part 2

### • StonglyConnectedComponents

Για την εύρεση των SCCs χρησιμοποιήθηκε ο αλγόριθμος του Tarjan, αλλά τροποποιημένος ώστε αντί αναδρομικά να τρέχει επαναληπτικά. Αυτή η αλλαγή επέτρεψε την επεξεργασία μεγαλύτερων workloads, στα οποία στην αναδρομική προσέγγιση "έσκαγε" η στοίβα.

#### • Grail Index

Και εδώ τροποποιήθηκε η αρχική αναδρομική υλοποίηση σε επαναληπτική. Επίσης, ο αριθμός των labels που επιλέχθηκε (πειραματικά, μετά από διάφορες δοκιμές) είναι 5.

### • (Weakly) Connected Components Index

Για την αρχική εύρεση των CC χρησιμοποιήθηκε Depth-First-Search. Η αποθήκευση τους γίνεται σε έναν πίνακα με μέγεθος ίσο με το πλήθος των κόμβων, και όταν γίνει ένωση μεταξύ δύο components χρησιμοποιείται η δομή Updated, η οποία υλοποιήθηκε και δοκιμάστηκε με τους εξής τρόπους:

- Η πρώτη υλοποιήση έγινε με την δομή της εκφώνησης η οποία φάνηκε να είναι η χειρότερη σε σχέση με τις άλλες δύο που δοκιμάστηκαν.
- Η δεύτερη υλοποιήση χρησιμοποιούσε ένα πίνακα με δείκτες σε λίστες (τις οποίες παίρνει απο μία δομη με επαναχρησιμοποιήσιμες λιστες (list pool)) με τα συνδεδεμένα components του κάθε cc. Ωστόσο αυτή η λύση απαίτουσε rebuild. Σε κάθε rebuild ενημερώνεται το ευρετήριο και "αδειάζονται" οι λίστες του updated. Κι αυτή η υλοποίηση όμως φάνηκε να μην είναι η καλύτερη απο αυτές που δοκιμάστηκαν.
- Η τρίτη και αυτή που επιλέξαμε για τον πίνακα updated χρησιμοποιεί disjoint sets με χρήση union by rank και path compression. Περισσότερες πληροφορίες βρίσκονται εδώ:
  Disjoint Sets (Wikipedia). Σε αυτή την υλοποιήση κρίναμε πως το rebuild στο update index δεν είναι απαραίτητο καθώς καλυπτεί αυτή την ανάγκη σε μεγάλο βαθμό το path compression.

## 4 Λεπτομέρειες υλοποίησης Part 3

#### • JobScheduler

Ο JobScheduler υλοποιήθηκε όπως ζητείται στην εκφώνηση. Ο τερματισμός των threads γίνεται με αποστολή queries με ειδικό version 0.

#### • Πολυνηματισμός

Έγιναν αλλαγές στον κώδικα των προηγούμενων parts, ώστε να είναι συμβατός με πολυνηματισμό. Σε αυτές περιλαμβάνονται: error handling & printing, το σύστημα versioning για την σωστή εκτέλεση των ερωτημάτων στους δυναμικούς γράφους, όπως επίσης το ότι οι ουρές και

οι δομές για μαρκάρισμα στις αναζητήσεις (και γενικά όπου ήταν απαραίτητο) μεταφέρθηκαν στα threads αντί να είναι μέλος του γράφου.

### • Connected Components Disjoint Sets

Καθώς κάθε ερώτημα έχει δικό του version, είναι απαραίτητη η διατήρηση των πληροφορίων όπως η ενώση μεταξυ CC, για κάθε version, στο πίνακα ευρετηρίου των CC και την δομη updated. Γι αυτό και στο updated για κάθε ενημέρωση οι πληροφορίες του κάθε CC (parent,rank,version) διατηρούνται σε λίστες στον πίνακα updated (οι οποίες δίνονται από το list pool). Για εξοικονόμηση μνήμης, αλλά και επείδη το path compression δεν είναι δυνάτο σε πλήρη βαθμό λόγω πολυνηματισμού, γίνεται rebuild στο τέλος κάθε ριπής με χρήση path compression. Έτσι ενημερώνεται ο βασικός πίνακας, και στην συνέχεια γίνεται το "άδειασμα" των λιστών καθιστώντας τες διαθέσιμες για μελλοντική χρήση σε άλλα CC, μειώνοντας έτσι την ανάγκη μνήμης.

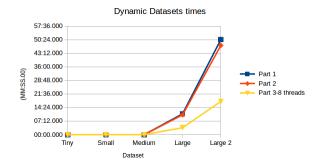
## 5 Μετρήσεις

Οι μετρήσεις έγιναν σε laptop με επεξεργαστή i7-3612QM (2.10 GHz, 4 cores, 8 threads) και μνήμη DDR3 1600MHz 8 GB. Για την μέτρηση των χρόνων χρησιμοποιήθηκε η συνάρτηση time και για την μέτρηση της απαιτούμενης χρησιμοποιούμε την τιμή (VmPeak) της τρέχουσας διεργασίας ( $cat/proc/pid\_of\_spath/status/grep~VmPeak$ ).

1. Παρακάτω ακολουθεί σύγκριση στους χρόνους και στην απαιτούμενη μνήμη για κάθε μέρος της εργασίας με εισόδους τα δυναμικά και τα στατικά datasets που δόθηκαν.

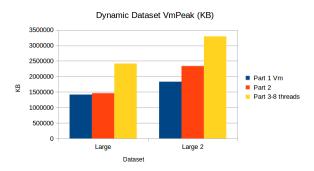
Πίναχας 1: Dynamic Datasets times

Dynamic	Dynamic Datasets times (MM:SS.000)					
	Part 1 Part 2 Part 3-8 three					
Tiny	00:00.001	00:00.002	00:00.004			
Small	00:00.453	00:00.519	00:00.596			
Medium	00:01.539	00:01.760	00:02.530			
Large		10:28.650				
Large 2	50:29.401	47:21.940	17:35.641			



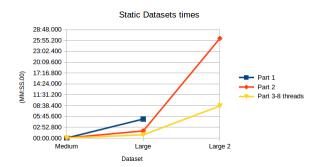
Πίναχας 2: Dynamic Datasets Memory Usage

Dynamic Dataset VmPeak (KB)						
	Part 1 Vm   Part 2   Part 3-8 threads					
Large	1414896	1458116	2414616			
Large 2	1829748	2335964	3291848			



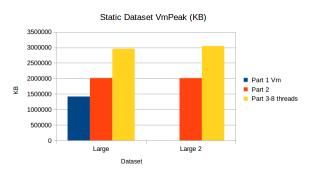
Πίνακας 3: Static Datasets times

Static Datasets times (MM:SS.000)							
	Part 1 Part 2 Part 3-8 threads						
Medium	00:01.434	00:02.538	00:02.637				
Large	05:03.604	01:54.640	00:51.800				
Large 2	>3H	26:28.035	08:31.369				



Πίναχας 4: Static Datasets Memory Usage

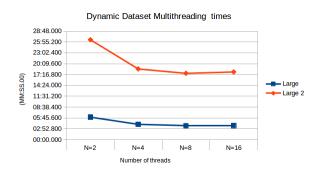
Static Datasets times (MM:SS.000)						
	Part 1 Part 2 Part 3-8 thread					
Medium	00:01.434	00:02.538	00:02.637			
Large	05:03.604	01:54.640	00:51.800			
Large 2	>3H	26:28.035	08:31.369			



2. Ακολουθεί σύγκριση των χρόνων και της απαιτούμενης μνήμης στο τελευταίο κομμάτι της εργασίας με παράμετρο τον αριθμό των νημάτων για δυναμικά και στατικά datasets.

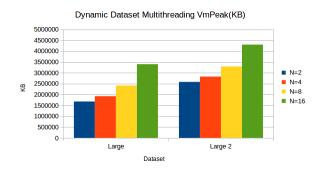
Πίνακας 5: Dynamic Dataset Multithreading times

Dynamic Dataset Multithreading times (MM:SS.000)						
Threads	Threads   N=2   N=4   N=8   N=16					
Large	05:57.266	04:03.300	03:41.225	03:42.664		
Large 2	26:30.534	18:45.376	17:35.641	17:57.566		



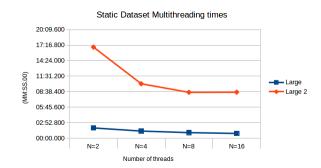
Πίναχας 6: Dynamic Dataset Multithreading Memory Usage

Dynamic Dataset Multithreading VmPeak(KB)					
Threads	N=2	N=4	N=8	N=16	
Large	1677284	1923060	2414616	3397252	
Large 2	2579536	2825312	3291848	4299972	



Πίνακας 7: Static Dataset Multithreading times

Static Dataset Multithreading times (MM:SS.000)					
Threads N=2					
				00:51.800	
Large 2	16:54.585	10:05.976	08:30.127	08:31.690	



Πίναχας 8: Static Dataset Multithreading Memory Usage

Static Dataset Multithreading VmPeak(KB)						
Threads	Threads   N=2   N=4   N=8   N=16					
Large	2222564	2468340	2959892	3943000		
Large 2	2307580	2553356	3044908	3950336		

