Ανάπτυξη Λογισμικού για Πληροφοριακά Συστήματα

Παναγιώτης Φωτόπουλος
sdi1300195@di.uoa.gr

Μάνος Πιτσικάλης
sdi1300143@di.uoa.gr

1 Εισαγωγή - Γενικά

2 Λεπτομέρειες υλοποίησης Part 1

- **Δομές αποθήκευσης**
  Για την αποθήκευση του γράφου χρησιμοποιούνται δύο ευρετήρια (index-buffer) ένα για τις εξερχόμενες ακμές και ένα για τις εισερχόμενες ακμές. Στις αναζητήσεις και όπου χρειάζονται λίστες,για την αποφυγή πολλών malloc, χρησιμοποιούνται λίστες υλοποιημένες με πίνακα, οι οποιές και επαναχρησιμοποιούνται όταν χρειαστεί. Δηλάδη γινέται μια φορά malloc, αν χρειαστεί γίνεται realloc, και με την λήξη της εκτέλεσης γίνεται η αποδέσμευση της μνήμης. Επιπλέον, στις αναζητήσεις και όπου αλλού χρειάζεται δομή για να σημαδεύονται οι κόμβοι (π.χ.στην bidirectional-bfs δομή visited) χρησιμοποιείται πίνακας A ίσος με των αριθμό των στοιχείων με versioning, δηλαδή αν το στοιχείο x έχει επισκεφτεί οταν γίνεται αναζήτηση με version v τότε A[x]=v, αν καποιό στοιχείο y δεν έχει επισκεφτεί τότε θα ισχύει A[y]<v, έτσι η αρχικοποιήση γίνεται μόνο μία φορά και ο έλεγχος γίνεται σε O(1).

- **Αναζήτηση**
  Για την αναζήτηση χρησιμοποιήθηκε η bidirectional Breadth-First Search, όπως περιγράφεται στην εκφώνηση, με τις εξής λεπτομέρειες και βελτιώσεις:

  – Στην αρχή της κάθε επανάληψης, θα επιλεχθεί για επέκταση η BFS η οποία έχει την χαμηλότερη τιμή στην εξής ευρετική:
  <αριθμός "παιδιών" προς επέκταση> + <αριθμός "εγγονιών" προς επέκταση (σε επόμενη επανάληψη)>
  Με αυτόν τον τρόπο, αποφεύγεται η σπατάλη χρόνου σε καταστάσεις όπου από τη μία κατεύθυνση υπάρχουν πάρα πολλά πιθανά μονοπάτια, ενώ από την άλλη λίγα ή μόνο ένα.

  – Η αναζήτηση γίνεται ανά "επίπεδα": Σε κάθε επανάληψη, η τρέχουσα BFS επισκέπτεται **όλα** τα παιδιά του τρέχοντος βάθους.

- **Unit testing**
  Έχει υλοποιηθεί unit testing στις βασικές δομές με χρήση check, για την σώστη λειτουργία του είναι απαραίτητο να υπάρχει αγκατεστημένο το Check.

- **Εισαγωγή ακμών**
  Κατά την εισαγωγή ακμών, ο έλεγχος ύπαρξης ακμής γίνεται στον κόμβο με τις λιγότερες ακμές στην αντίστοιχη κατεύθυνση (εισερχόμενες-εξερχόμενες) για εξοικονόμηση χρόνου. Δοκιμάστηκε η χρήση hashtable για να γίνεται σε O(1) ο έλεγχος αυτός, αλλά αυτή η προσέγγιση αποδείχθηκε

μη αποδοτική καθώς επηρέαζε σημαντικά τη χρήση μνήμης, καθώς και τον συνολικό χρόνο (ενημέρωση του hashtable). Σημείωση υπάρχουν τα αρχεία για το hash table (hash.c,hash.h) αλλά δεν χρησιμοποιούνται στο τελικό πρόγραμμα.

3 Λεπτομέρειες υλοποίησης Part 2

- **StonglyConnectedComponents**
  Για την εύρεση των SCCs, χρησιμοποιήθηκε ο αλγόριθμος του Tarjan, αλλά τροποποιημένος ώστε αντί αναδρομικά να τρέχει επαναληπτικά. Αυτή η αλλαγή επέτρεψε την επεξεργασία μεγαλύτερων workloads, στα οποία στην αναδρομική προσέγγιση "έσκαγε" η στοίβα.

- **Grail Index**
  Και εδώ τροποποιήθηκε η αρχική αναδρομική υλοποίηση σε επαναληπτική. Επίσης, ο αριθμός των labels που επιλέχθηκε (πειραματικά, μετά από διάφορες δοκιμές) είναι 5.

- **(Weakly) Connected Components Index**
  Για την αρχική εύρεση των CC χρησιμοποιήθηκε Depth-First-Search. Η αποθήκευση τους γίνεται σε έναν πίνακα με μέγεθος ίσο με το πλήθος των κόμβων, και όταν γίνει ένωση μεταξύ δύο components χρησιμοποιείται η δομή Updated η οποία υλοποιήθηκε και δοκιμάστηκε με τους εξής τρόπους :

  – Η πρώτη υλοποιήση έγινε με την δομή της εκφώνησης η οποία φάνηκε να είναι η χειρότερη σε σχέση με τις άλλες δύο που δοκιμάστηκαν.
  – Η δεύτερη υλοποιήση χρησιμοποιούσε ένα πίνακα με δείκτες σε λίστες (τις οποίες παίρνει απο μία δομη με επαναχρησιμοποιήσιμες λιστες (list pool)) με τα συνδεδεμένα components του κάθε cc. Ωστόσο αυτή η λύση απαίτουσε rebuild. Σε κάθε rebuild ενημερώνεται το ευρετήριο και "αδειάζονται" οι λίστες του updated. Κι αυτή η υλοποίηση όμως φάνηκε να μην είναι η καλύτερη απο αυτές που δοκιμάστηκαν.
  – Η τρίτη και αυτή που επιλέξαμε για τον πίνακα updated χρησιμοποιεί disjoint sets με χρήση union by rank και path compression. Περισσότερες πληροφορίες βρίσκονται εδώ: Disjoint Sets (Wikipedia). Σε αυτή την υλοποιήση κρίναμε πως το rebuild στο update index δεν είναι απαραίτητο καθώς καλυπτεί αυτή την ανάγκη σε μεγάλο βαθμό το path compression.

4 Λεπτομέρειες υλοποίησης Part 3

- **JobScheduler**
  Ο JobScheduler υλοποιήθηκε όπως ζητείται στην εκφώνηση. Ο τερματισμός των threads γίνεται με αποστολή queries με version 0.

- **Πολυνηματισμός**
  Έγιναν αλλαγές στον κώδικα των προηγούμενων parts, ώστε να είναι συμβατός με τον πολυνηματισμό. Σε αυτές περιλαμβάνονται: error handling & printing, οι ουρές και οι δομές για μαρκάρισμα για τις αναζητήσεις (και γενικά όπου ήταν απαραίτητο) μεταφέρθηκαν στα thread αντί να είναι μέλος του γράφου, καθώς και το σύστημα versioning για την σωστή εκτέλεση των ερωτημάτων στους δυναμικούς γράφους.

- **Connected Components Disjoint Sets**
  Καθώς κάθε ερώτημα έχει δικό του version, είναι απαραίτητη η διατήρηση των πληροφορίων όπως η ενώση μεταξυ CC, για κάθε version, στο πίνακα ευρετηρίου των CC και την δομη updated. Γι αυτό και στο updated για κάθε ενημέρωση οι πληροφορίες του κάθε CC (parent,rank,version) διατηρούνται σε λίστες στον πίνακα updated (οι οποίες δίνονται από το list pool). Για εξοικονόμηση μνήμης, αλλά και επείδη το path compression δεν είναι δυνάτο σε πλήρη βαθμό λόγω πολυνηματισμού, γίνεται rebuild στο τέλος κάθε ριπής με χρήση path compression. Έτσι ενημερώνεται ο βασικός πίνακας, και στην συνέχεια γίνεται το "άδειασμα" των λιστών καθιστώντας τες διαθέσιμες για μελλοντική χρήση σε άλλα CC, μειώνοντας έτσι την ανάγκη μνήμης.

5 Μετρήσεις

Οι μετρήσεις έγιναν σε laptop με επεξεργαστή i7-3612QM (2.10 GHz, 4 cores, 8 threads) και μνήμη DDR3 1600MHz 8 GB. Για την μέτρηση των χρόνων χρησιμοποιήθηκε η συνάρτηση time και για την μέτρηση της απαιτούμενης χρησιμοποιούμε την τιμή (VmPeak) της τρέχουσας διεργασίας (*cat /proc/pid_of_spath/status |grep VmPeak*).

1. Παρακάτω ακολουθεί σύγκριση στους χρόνους και στην απαιτούμενη μνήμη για κάθε μέρος της εργασίας με εισόδους τα δυναμικά και τα στατικά datasets που δόθηκαν.

Πίνακας 1: Dynamic Datasets times

Dynamic Datasets times (MM:SS.000)			
	Part 1	Part 2	Part 3-8 threads
Tiny	00:00.001	00:00.002	00:00.004
Small	00:00.453	00:00.519	00:00.596
Medium	00:01.539	00:01.760	00:02.530
Large	11:01.551	10:28.650	03:41.225
Large 2	50:29.401	47:21.940	17:35.641

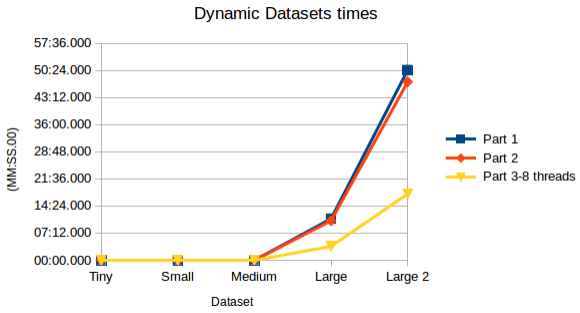

Πίνακας 2: Dynamic Datasets Memory Usage

Dynamic Dataset VmPeak (KB)			
	Part 1 Vm	Part 2	Part 3-8 threads
Large	1414896	1458116	2414616
Large 2	1829748	2335964	3291848

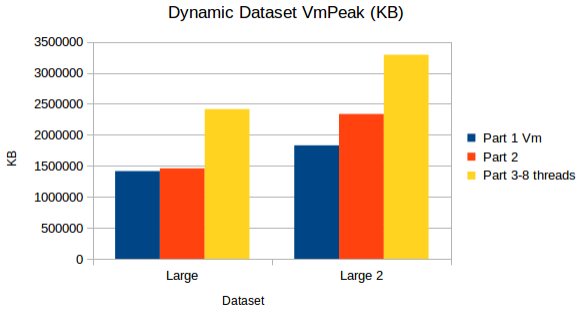

Πίνακας 3: Static Datasets times

Static Datasets times (MM:SS.000)			
	Part 1	Part 2	Part 3-8 threads
Medium	00:01.434	00:02.538	00:02.637
Large	05:03.604	01:54.640	00:51.800
Large 2	>3H	26:28.035	08:31.369

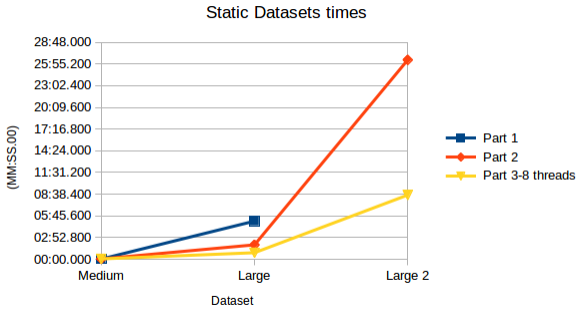

Πίνακας 4: Static Datasets Memory Usage

Static Datasets times (MM:SS.000)			
	Part 1	Part 2	Part 3-8 threads
Medium	00:01.434	00:02.538	00:02.637
Large	05:03.604	01:54.640	00:51.800
Large 2	>3H	26:28.035	08:31.369

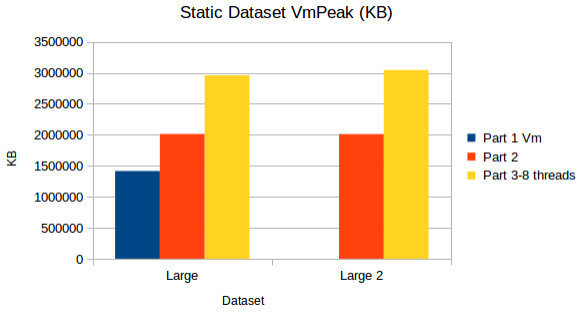

2. Ακολουθεί σύγκριση των χρόνων και της απαιτούμενης μνήμης στο τελευταίο κομμάτι της εργασίας με παράμετρο τον αριθμό των νημάτων για δυναμικά και στατικά datasets.

Πίνακας 5: Dynamic Dataset Multithreading times

Dynamic Dataset Multithreading times (MM:SS.000)				
Threads	N=2	N=4	N=8	N=16
Large	05:57.266	04:03.300	03:41.225	03:42.664
Large 2	26:30.534	18:45.376	17:35.641	17:57.566

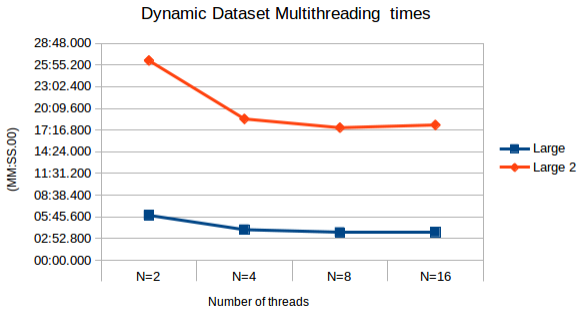

Πίνακας 6: Dynamic Dataset Multithreading Memory Usage

Dynamic Dataset Multithreading VmPeak(KB)				
Threads	N=2	N=4	N=8	N=16
Large	1677284	1923060	2414616	3397252
Large 2	2579536	2825312	3291848	4299972

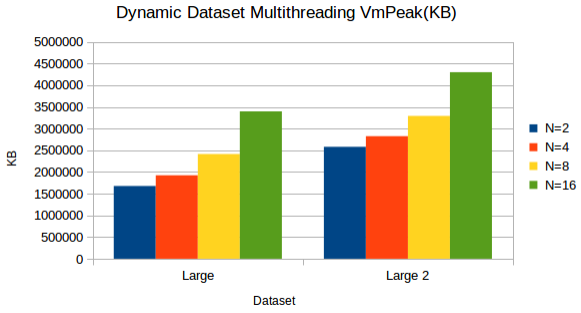

Πίνακας 7: Static Dataset Multithreading times

Static Dataset Multithreading times (MM:SS.000)				
Threads	N=2	N=4	N=8	N=16
Large	01:53.454	01:18.555	01:01.018	00:51.800
Large 2	16:54.585	10:05.976	08:30.127	08:31.690

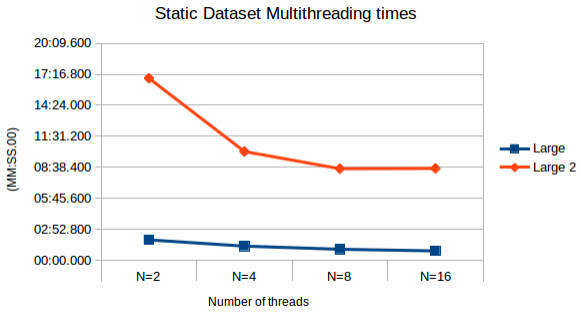

Πίνακας 8: Static Dataset Multithreading Memory Usage

Static Dataset Multithreading VmPeak(KB)				
Threads	N=2	N=4	N=8	N=16
Large	2222564	2468340	2959892	3943000
Large 2	2307580	2553356	3044908	3950336